

# 主成分分析

Principal Component Analysis

王栋

[wdice@dlut.edu.cn](mailto:wdice@dlut.edu.cn)

信息与通信工程学院

# 内容提要

- ① 预备知识
- ② 问题介绍
- ③ 算法推导和解释
- ④ 自然图像的主成分
- ⑤ 总结

# ① 预备知识

## ② 问题介绍

## ③ 算法推导和解释

## ④ 自然图像的主成分

## ⑤ 总结

# 预备知识

- 基（坐标）变换，空间和子空间

参看第三讲最小二乘预备知识

- SVD分解和特征值分解

参看最后一页PPT

- 拉格朗日乘子法

google: 维基百科, 拉格朗日乘数

- KL (Karhunen-Loeve)变换


参看PCA人脸识别

- 《Eigenfaces for Face Detection/Recognition》

理解特征脸算法与PCA算法最大不同（“技巧加速”）

理解特征脸的含义（“基向量的可视化”）和物理意义（“任何一个人脸都可以看做平均脸和特征脸的线性组合”）

# 从坐标变换看PCA



从坐标变换看PCA以及压缩

$$\begin{bmatrix} -1 \\ -1 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \dots, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \leftarrow \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} -\sqrt{2} \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \dots, \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} \leftarrow \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \\ \sqrt{2}/2 & -\sqrt{2}/2 \end{bmatrix}$$

① 预备知识

② 问题介绍

③ 算法推导和解释

④ 自然图像的主成分

⑤ 总结

# 问题介绍

- 给定  $n$  个  $m$  维的样本  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  ( $\mathbf{x}_i \in \mathbb{R}^{m \times 1}$ ), 主成分分析 (PCA) 的目的寻找一个均值  $\mu$ , 和一组正交基向量  $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d]$  ( $d < \min(m, n)$ ) 来**最优**的表示给定的样本。

$$\min \sum_{i=1}^n \|\mathbf{x}_i - (\mu + \mathbf{U}\mathbf{y}_i)\|_2^2,$$

这里的  $\mathbf{y}_i$  称为表示系数。假设我们已经知道了  $\mathbf{U}$  和  $\mu$ , 那么最优的  $\mathbf{y}_i$  就为:  $\mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \mu)$ 。注意: 与最小二乘类比。

$$\min \sum_{i=1}^n \|\mathbf{x}_i - (\mu + \mathbf{U}\mathbf{y}_i)\|_2^2 \Rightarrow \min \|\mathbf{x}_i - (\mu + \mathbf{U}\mathbf{y}_i)\|_2^2$$

$$\Rightarrow \min \|(\mathbf{x}_i - \mu) - \mathbf{U}\mathbf{y}_i\|_2^2 \Rightarrow \mathbf{y}_i = (\mathbf{U}^\top \mathbf{U})^{-1} \mathbf{U}^\top (\mathbf{x}_i - \mu)$$

$$\Rightarrow \mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \mu)$$

$$\text{原问题转化为: } \min \sum_{i=1}^n \|\mathbf{x}_i - \mu - \mathbf{U}\mathbf{U}^\top (\mathbf{x}_i - \mu)\|_2^2$$

① 预备知识

② 问题介绍

③ 算法推导和解释

④ 自然图像的主成分

⑤ 总结



# 问题介绍

- 回顾原问题：

$$\min \sum_{i=1}^n \left\| \mathbf{x}_i - \mu - \mathbf{U}\mathbf{U}^\top (\mathbf{x}_i - \mu) \right\|_2^2$$

$$s.t. \mathbf{U}\mathbf{U}^\top = \mathbf{I}$$

- 注意：要把 $\ell_2$ 范数和i.i.d高斯噪声假设联系起来。所以PCA的假设也是噪声服从i.i.d高斯分布。所以PCA也不能处理Outliers的问题（回顾上一讲的最小二乘问题）。
- Robust Principal Component Analysis (Low Rank Matrix Recovery)  
<http://perception.csl.illinois.edu/matrix-rank/home.html>
- Online Object Tracking with Sparse Prototypes  
<http://ice.dlut.edu.cn/lu/Project/TIP12-SP/TIP12-SP.htm>

# 均值推导和解释

- 均值的推导:

$$\mu = \arg \min_{\mu} \sum_{i=1}^n (\mathbf{x}_i - \mu)_2^2$$

$$J(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)_2^2 = \sum_{i=1}^n (\mathbf{x}_i - \mu)^T (\mathbf{x}_i - \mu)$$

$$\frac{\partial J}{\partial \mu} = -2 \sum_{i=1}^n (\mathbf{x}_i - \mu) = 0 \Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

- 均值的解释

- 如果我们只用一个向量来近似所有样本，均值就是最佳的选择。
- 类比信号的直流分量，均值可以看作样本数据集的零维表达。
- 均值向量简单而且描述了样本数据集的最大共性，但是缺点是不能反映出样本数据集的不同。
- 补充阅读：《模式分类》中文版，第94页，另一种方式的推导。

# 基向量推导和解释

- 最小误差V.S.最大方差：（令  $\bar{\mathbf{x}}_i = \mathbf{x}_i - \mu$ ）

$$\mathbf{u} = \arg \min_{\mathbf{u}} \sum_{i=1}^n \|\bar{\mathbf{x}}_i - \mathbf{u} \mathbf{u}^\top \bar{\mathbf{x}}_i\|_2^2 \quad \text{等价于}$$

$$s.t. \quad \|\mathbf{u}\|_2^2 = 1$$

$$\mathbf{u} = \arg \max_{\mathbf{u}} \mathbf{u}^\top \left( \sum_{i=1}^n \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top \right) \mathbf{u}$$

$$s.t. \quad \|\mathbf{u}\|_2^2 = 1$$

- 令  $S = \sum_{i=1}^n \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top$  称为散布矩阵（Scatter Matrix）。我们可以看出

它和协方差矩阵（Covariance Matrix）  $C = \frac{1}{n-1} \left( \sum_{i=1}^n \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top \right)$  只相差个倍数。

- 所以，对于PCA有两种原则解释：（1）最小重构误差原则；  
（2）最大方差原则。两者之间是等价的。

# 最小误差v.s.最大方差细节推导

$$\begin{aligned}
 & \sum_{i=1}^n \|\bar{\mathbf{x}}_i - \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i\|_2^2 \\
 &= \sum_{i=1}^n (\bar{\mathbf{x}}_i - \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i)^\top (\bar{\mathbf{x}}_i - \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i) \\
 &= \sum_{i=1}^n \bar{\mathbf{x}}_i^\top \bar{\mathbf{x}}_i - \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i - \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i + \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i \\
 & \quad (\mathbf{u}^\top \mathbf{u} = \|\mathbf{u}\|_2^2 = 1) \\
 &= \sum_{i=1}^n \bar{\mathbf{x}}_i^\top \bar{\mathbf{x}}_i - \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i - \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i + \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i \\
 & \quad (\mathbf{u}^\top \bar{\mathbf{x}}_i = \bar{\mathbf{x}}_i^\top \mathbf{u}, \bar{\mathbf{x}}_i^\top \mathbf{u}\mathbf{u}^\top \bar{\mathbf{x}}_i = \mathbf{u}^\top \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top \mathbf{u}) \\
 &= - \left( \sum_{i=1}^n \mathbf{u}^\top \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top \mathbf{u} \right) + \sum_{i=1}^n \bar{\mathbf{x}}_i^\top \bar{\mathbf{x}}_i \\
 &= -\mathbf{u}^\top \left( \sum_{i=1}^n \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top \right) \mathbf{u} + \sum_{i=1}^n \bar{\mathbf{x}}_i^\top \bar{\mathbf{x}}_i
 \end{aligned}$$

补充阅读：《模式分类》中文版，第95页，另一种方式的推导。

# 利用特征值分解来求基向量

- 回顾目标函数：

$$\mathbf{u} = \arg \max_{\mathbf{u}} \mathbf{u}^{\top} \mathbf{S} \mathbf{u} \quad \left( \mathbf{S} = \sum_{i=1}^n \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^{\top} \right)$$

$$s.t. \mathbf{u}^{\top} \mathbf{u} = 1$$

- 拉格朗日乘子法：

$$J(\mathbf{u}) = \mathbf{u}^{\top} \mathbf{S} \mathbf{u} - \lambda \mathbf{u}^{\top} \mathbf{u}$$

$$\Rightarrow \frac{\partial J}{\partial \mathbf{u}} = 2\mathbf{S} \mathbf{u} - 2\lambda \mathbf{u} = 0 \Rightarrow \mathbf{S} \mathbf{u} = \lambda \mathbf{u}$$

所以最优

的 $\mathbf{u}$ 为**最大**特征值对应的特征向量。

- 这是选取一个基向量 $\mathbf{u}$ 的证明。扩展到选取 $d$ 个基向量，就是**选取前 $d$ 个特征值对应的特征向量**。
- 为什么要选取最大的特征值对应的特征向量？** 目标函数 $\mathbf{u}^{\top} \mathbf{S} \mathbf{u} = \mathbf{u}^{\top} \lambda \mathbf{u} = \lambda$ 。关键看目标函数是**最大**还是**最小**。最大化目标函数当然选择最大特征值，如：PCA，LDA算法。最小化目标函数当然选择最小特征值，如：LPP，LLE，N-Cut算法。

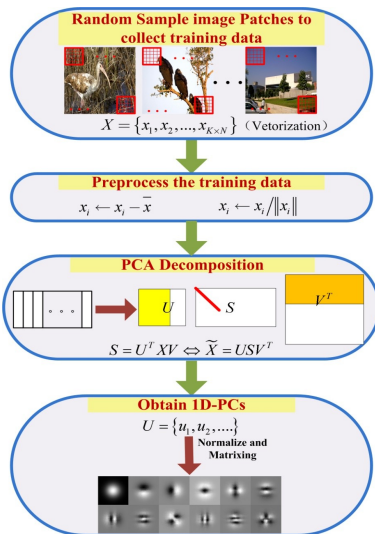
- ① 预备知识
- ② 问题介绍
- ③ 算法推导和解释
- ④ 自然图像的主成分
- ⑤ 总结

# 自然图像主成分分析步骤


- (1)在自然图像数据库上采样  $S \times S$  的小块组成训练样本。
  - (2)数据预处理：向量化，去均值，归一化。
  - (3)进行PCA分解。
- 最后，得到的特征向量被称为**自然图像的主成分**。

自然图像的主成分用途：

- (1)加深我们对PCA的理解；
- (2)用于纹理特征提取，如PPBTF。



# 自然图像主成分显示和分析



自然图像主成分显示(前36个)

第1个主成分相当于高斯滤波器，第2,3个主成分相当于一阶导数滤波器，第4,5个主成分相当于二阶导数滤波器。而后面的主成分越来越像杂乱的噪声模式。**理解：PCA类似于低通滤波，越靠前的主成分越能用于表征图像的低频信息。**



- ① 预备知识
- ② 问题介绍
- ③ 算法推导和解释
- ④ 自然图像的主成分
- ⑤ 总结

# 总结

- 需要从坐标变换（基变换）角度理解PCA。  
PCA的目的是找到**最能够表示**样本数据的主方向（或基函数，坐标轴）。
- PCA的**两个原则**：最小重构误差原则和最大方差原则，及等价性。
- 掌握利用（广义）特征值分解来求解基向量的推导和意义。**尤其要理解为什么选择最大特征值对应的特征向量**。看目标函数是最大还是最小。  
（注：以后很多算法如LDA，LPP，LLE，NCut等会用到）。
- 从SVD分解或因子分解的角度看PCA（下页图解）。

# SVD分解和PCA

